

Sepehr Mahmoudian

SENIOR-KI-ENTWICKLER

Machine Learning • Wissensgraphen • Multimodale KI & Embodied AI

E-MAIL sepmhn@gmail.com

GITHUB github.com/sepahead

LINKEDIN linkedin.com/in/sepehr-mahmoudian

Berlin-Brandenburg • verfügbar ab November 2026 • Staatsangehörigkeit: deutsch • Deutsch: gut / Englisch: fließend / Persisch: Muttersprache



PROFIL

Entwickelt maßgeschneiderte Agenten-Harnesses für Fachanwendungen, Wissensgraphen und Graph RAG; evaluiert LLM-, VLM- und VLA-Systeme sowie World Models und verbindet agentische Orchestrierung mit konsequentem agentischen Engineering.

LLMs / VLMs • Wissensgraphen • Agentic Vision • Multimodale KI • Szenenrekonstruktion
CONTEXT ENGINEERING • DATENPROVENIENZ • MODELLEVALUATION • REINFORCEMENT LEARNING

KI-ENGINEERING

10+ JAHRE

FORSCHUNG BIS PRODUKTIVEINSATZ

PYTHON • RUST • KI / ML

BERUFSERFAHRUNG

Selbstständiger KI- und ML-Entwickler & Doktorand

2020.04 - heute

Selbstständig; Promotion an der Technischen Universität Darmstadt

• Berlin & Darmstadt, Deutschland

- Biophysikalische/funktionale neuronale Modelle, PID (Partial Information Decomposition), VLA-Evaluation und neuronale Steuerung
- Aufbau domänenspezifischer KI-Agenten-Harnesses; multimodale 3D-Wahrnehmung und prüfbare Visualisierung

Senior-KI-Entwickler

2026.01 - 2026.03

Neural Frames UG

• Berlin & Hamburg, Deutschland

- Evaluation von LLMs, VLMs und End-to-End-Pipelines; Langfuse-Tracing von Läufen und Ergebnissen
- Begrenzte Mitarbeit an Python-Pipelines für Modellevaluation und Inferenz

KI-Engineering-Resident

2025.09 - 2026.01

Merantix AI Campus (Hacker Room)

• Berlin, Deutschland

- Entwicklung generativer Mediensysteme mit Gaussian Splatting und Diffusionsmodellen zur räumlich-zeitlichen Verankerung
- Implementierung von Smart Contracts in Rust für Confidential Computing
- Bereitstellung von Produktservices und Dateninfrastruktur auf Cloudflare Workers, D1, R2, Google Cloud Run und AWS EC2

Senior-KI-Entwickler

2024.07 - 2025.07

Vision Labs UG

• Berlin & Hamburg, Deutschland

- Aufbau von Workflows für Prompt-Optimierung, LLM-Evaluation und Observability mit DSPy und Langfuse
- Konzeption von Daten- und MLOps-Pipelines auf Azure und Google Cloud mit Staging, automatisierten Tests und CI/CD

Wissenschaftlicher Mitarbeiter

2021.07 - 2024.07

Freie Universität Berlin

• Berlin, Deutschland

- Skalierung und Optimierung groß angelegter Simulationen neuronaler Netze in C/C++ und Python
- Entwicklung von RAG-Workflows für Fachliteratur und Evaluation der Zuverlässigkeit von KI-Agenten
- Statistische und ML-Analysen in Python; Code- und Manuskriptreviews in einem internationalen Team

Wissenschaftlicher Mitarbeiter

2019.07 - 2020.06

Georg-August-Universität Göttingen • Göttingen, Deutschland

Neuronale Netze, Partial Information Decomposition (PID), Informationstheorie und reproduzierbare Daten-Workflows

Wissenschaftlicher Mitarbeiter

2017.03 - 2019.07

Goethe-Universität Frankfurt • Frankfurt am Main, Deutschland • Simulation und statistische Analyse neuronaler Netzmodelle

Gastwissenschaftler

2017.03 - 2019.03

Max-Planck-Institut für Dynamik und Selbstorganisation • Göttingen, Deutschland • Statistische Methoden zur Analyse neuronaler Netze

Wissenschaftlicher Mitarbeiter

2015.02 - 2017.03

Forschungszentrum Jülich • Jülich, Deutschland • Simulationen neuronaler Netze und Experimente zum Reinforcement Learning

Softwareentwickler

2010.09 - 2012.03

Centre for Content Creation • Cyberjaya, Malaysia • Preisgekrönte iPhone- und iPad-Anwendungen sowie digitale Produkte

AKADEMISCHE AUSBILDUNG

Promotion zum Dr. rer. nat.

2020.04 - heute

Technische Universität Darmstadt • Darmstadt, Deutschland

• Neue mathematische PID-Analysen und informationstheoretische Repräsentationsanalyse; Engrams domänenspezifischer KI-Agent erzeugt für reproduzierbare Computational-Neuroscience-Workflows provenienzengebundene neuronale Modellkandidaten für Closed-Loop-Netzwerksimulationen mit begrenzten Kompilierungs- und Simulationsprüfungen

Master of Research in Biowissenschaften: Neurowissenschaften

2012 - 2014

University College London • London, Vereinigtes Königreich

Computational Neuroscience • Abschluss mit Auszeichnung (Distinction, Top 10 %, CGPA 4.0/4.0)

Bachelor of Science (Honours) in Informatik

2009 - 2012

Anglia Ruskin University • Cambridge, Vereinigtes Königreich

Abschluss mit First Class Honours (Top 1 %, CGPA 4.0/4.0)

AUSGEWÄHLTE AUSZEICHNUNGEN & FÖRDERUNGEN

- EDTH / 2025
Special Mention beim European Defense Tech Hackathon Berlin 2025; mitveranstaltet vom Cyber Innovation Hub der Bundeswehr
- HUMAN BRAIN PROJECT
Forschungsförderung

- NEAR HORIZON
Förderung für Confidential Computing
- UCL & SHEFFIELD
Im Wettbewerb vergebene Hochschulstipendien
- IOS-ANWENDUNGEN
15 internationale Produktauszeichnungen



UNTERSCHRIFT

Sepehr Mahmoudian

ORT Berlin, Deutschland

DATUM 26. August 2026

ÖFFENTLICHES ENGINEERING-PORTFOLIO

GITHUB Open-Source-Projekte

github.com/sepahead

HUGGING FACE Modelle & Datensätze

huggingface.co/torusprime



AUSGEWÄHLTE PROJEKTE



engram

★ 15

FORSCHUNGSPROTOTYP

PROVENIENZGEBUNDENE NEURONALE FORSCHUNG

Domänenspezifischer KI-Agent überführt qualifizierte Evidenz in neuronale Modellkandidaten; Kompilierung und Simulation werden begrenzt geprüft.

Neuronale Netze

Wissensgraphen

Closed-Loop-Simulation



prisoma

★ 2

V0.9-VORABVERSION / AKTIVE F&E

PRÜFBARE CLOSED-LOOP-EXPERIMENTE

Simulationsumgebung für Closed-Loop-Experimente mit VLA- und World-Model-Systemen; Aufzeichnung, Replay und Provenienz.

Rust / Python

VLA + World Models

Verkörperte Simulation



manwe

★ 3

ALPHA

LUFTRAUMWAHRNEHMUNG

Forschungswerkzeug für Bilddaten, Akustik, Mehrkamergeometrie und Tracking; Modellexporte durchlaufen Artefaktidentitäts- und Numerikprüfungen.

Python

PyTorch

Multimodale Wahrnehmung



melkor

★ 13

HÄRTUNG

INTEGRITÄT VON GAUSSIAN SPLATS

Prüft und konvertiert 3D-Gaussian-Splats deterministisch; legt numerische Risiken und Feldherkunft vor dem Pipeline-Einsatz offen.

C++

Szenenrekonstruktion

Asset-Validierung



galadriel

★ 7

FORSCHUNGSPROTOTYP

SENSORÜBERGREIFENDE KONSISTENZ

Fail-Closed-Monitor für Sensorwidersprüche auf einer Objektspur; Innovationstests und vorzeichenbehaftete Korrelation auf deklarierten Projektionen.

Rust

NIS / CUSUM

Vorzeichenbehaftete Korrelation



pid-rs

★ 14

V0.9-QUELLVORABVERSION

PRÜFBARE INFORMATIONSZERLEGUNG

Misst, wie viel Information mehrere Signale über eine Zielgröße teilen; eingebaute Prüfungen und Provenienz sichern reproduzierbare Ergebnisse.

Rust / Python

Informationstheorie

Statistisches ML



NCP

★ 16

V0.8-RELEASE / 1.0-RC BLOCKIERT

PROTOKOLL FÜR NEURONALE STEUERUNG

Verbindet neuronale Simulatoren, KI-Controller und Roboter über vier typisierte Ebenen mit lokalen Fail-Safes und Provenienz.

Rust

Typisierte Steuerungsebenen

Zenoh



crebain

★ 21

FORSCHUNGSPROTOTYP

RÄUMLICHES LAGEBILD

Bündelt Gaussian-Splat-Szenen, native Objekterkennung und multimodales 3D-Tracking in einer taktischen Ansicht für simulierte Drohneneinsätze.

Rust

Sensorfusion

Native Inferenz



cobot-atlas relief-atlas

★ 7

↑ 1.850

VERÖFFENTLICHT + DOI

KI-GENERIERTE SIMULATIONSDATENSÄTZE

2.023 Robotik- und 10.079

Katastrophenschutz-GLB-Meshes mit Erzeugungspipelines.

Python

Hugging Face

3D / VLA



cortexel

★ 4

0.10.0-DEV.0

PRÜFBARE NEURONALE ABBILDUNGEN

Prüft wissenschaftliche Abbildungen gegen deklarierte Verträge; Diagramme passen nachweislich zu den Daten und bleiben reproduzierbar.

Abbildungsverträge

Deterministisches SVG

Provenienz

PORTFOLIO & ENTWICKLUNGSAKTIVITÄT

9.831

GITHUB-BEITRÄGE SEIT 2014

23


ÖFFENTLICHE REPOSITORIES OHNE FORKS

112

STARS AUF ÖFFENTLICHEN REPOSITORIES

138

AKTIVE TAGE IN 2026



AKTUELLE DYNAMIK

2,64× Beiträge 2026 bisher gegenüber dem Gesamtjahr 2025

5.353 bisher • 2.027 im Jahr 2025

BEITRÄGE NACH WOCHENTAG



5.353 Beiträge • 2026 bisher

Mo	16,8%	Di	13,5%
Mi	11,9%	Do	9,5%
Fr	11,7%	Sa	18,2%
So	18,5%		

TECHNISCHE KENNTNISSE

• AGENTISCHE KI	LLMs / VLMs Agent Harnesses AI Agents Tool Use Model Evaluation Inference Pipelines
• MACHINE LEARNING	Python PyTorch Agentic Vision Multimodal AI Vision-Language-Action / VLA Evaluation
• WISSEN & RETRIEVAL	Knowledge Graphs Graph RAG RAG Embeddings Vector Search Reranking Data Provenance
• SYSTEME & MLOPS	Rust C++ FastAPI ONNX TensorRT CUDA Metal / Core ML Docker
• CLOUD & INFRASTRUKTUR	GCP AWS Azure Kubernetes Terraform GitHub Actions Linux Zenoh