Sepehr Mahmoudian

SENIOR-KI-ENTWICKLER

Machine Learning • Wissensgraphen • Multimodale KI & Embodied AI



E-MAIL sepmhn@gmail.com

GITHUB github.com/sepahead

LINKEDIN linkedin.com/in/sepehr-mahmoudian

Berlin-Brandenburg • verfügbar ab Januar 2027 • Staatsangehörigkeit: deutsch • Deutsch: gut / Englisch: fließend / Persisch: Muttersprache

PROFIL

Entwickelt domänenspezifische Agenten-Harnesses, Wissensgraphen und Graph RAG; orchestriert agentische Workflows und evaluiert LLMs, VLMs, VLAs und World Models. Expertise in formalen Methoden und Verifikation.

LLMs / VLMs • Wissensgraphen • Agentic Vision • Multimodale KI • Szenenrekonstruktion

CONTEXT ENGINEERING • DATENPROVENIENZ • MODELLEVALUATION • REINFORCEMENT LEARNING

KI-ENGINEERING

10+ JAHRE

FORSCHUNG BIS PRODUKTIVEINSATZ

PYTHON • RUST • KI / ML

BERUFSERFAHRUNG

Selbstständiger KI- und ML-Entwickler & Doktorand

2020.04 - heute

Selbstständig; Promotion an der Technischen Universität Darmstadt — Berlin & Darmstadt, Deutschland

- Biophysikalische/funktionale neuronale Modelle, PID (Partial Information Decomposition), VLA-Evaluation und neuronale Steuerung
- Aufbau domänenspezifischer KI-Agenten-Harnesses; multimodale 3D-Wahrnehmung und prüfbare Visualisierung

Senior-KI-Entwickler

2026.01 - 2026.03

Neural Frames UG — Berlin & Hamburg, Deutschland

- Evaluation von LLMs, VLMs und End-to-End-Pipelines; Langfuse-Tracing von Läufen und Ergebnissen
- Mitarbeit an Python-Pipelines für Modellevaluation und Inferenz; Einsatz formaler Methoden und Verifikation

KI-Engineering-Resident

2025.09 - 2026.01

Merantix AI Campus (Hacker Room) — Berlin, Deutschland

- Entwicklung generativer Mediensysteme mit Gaussian Splatting und Diffusionsmodellen zur räumlich-zeitlichen Verankerung
- Implementierung von Smart Contracts in Rust für Confidential Computing
- Bereitstellung von Produktservices und Dateninfrastruktur auf Cloudflare Workers, D1, R2, Google Cloud Run und AWS EC2

Senior-KI-Entwickler

2024.07 - 2025.07

Vision Labs UG — Berlin & Hamburg, Deutschland

- Aufbau von Workflows für Prompt-Optimierung, LLM-Evaluation und Observability mit DSPy und Langfuse
- Konzeption von Daten- und MLOps-Pipelines auf Azure und Google Cloud mit Staging, automatisierten Tests und CI/CD

Wissenschaftlicher Mitarbeiter

2021.07 - 2024.07

Freie Universität Berlin — Berlin, Deutschland

- Skalierung und Optimierung groß angelegter Simulationen neuronaler Netze in C/C++ und Python
- Entwicklung von RAG-Workflows für Fachliteratur und Evaluation der Zuverlässigkeit von KI-Agenten
- Statistische und ML-Analysen in Python; Code- und Manuskriptreviews in einem internationalen Team

Wissenschaftlicher Mitarbeiter
2019.07 - 2020.06

Georg-August-Universität Göttingen Göttingen, Deutschland

Neuronale Netze, Partial Information Decomposition (PID), Informationstheorie und reproduzierbare Daten-Workflows

Wissenschaftlicher Mitarbeiter
2017.03 - 2019.07

Goethe-Universität Frankfurt Frankfurt am Main, Deutschland · Simulation und statistische Analyse neuronaler Netzmodelle

Gastwissenschaftler
2017.03 - 2019.03

Max-Planck-Institut für Dynamik und Selbstorganisation Göttingen, Deutschland · Statistische Methoden zur Analyse neuronaler Netze

Wissenschaftlicher Mitarbeiter
2015.02 - 2017.03

Forschungszentrum Jülich Jülich, Deutschland · Simulationen neuronaler Netze und Experimente zum Reinforcement Learning

Softwareentwickler
2010.09 - 2012.03

Centre for Content Creation Cyberjaya, Malaysia · Preisgekrönte iPhone- und iPad-Anwendungen sowie digitale Produkte

AKADEMISCHE AUSBILDUNG

Promotion zum Dr. rer. nat.
2020.04 - heute

Technische Universität Darmstadt Darmstadt, Deutschland

Dissertation: Partielle Informationszerlegung und Closed-Loop-Simulation neuronaler und verkörperter Systeme auf formal verifizierten Grundlagen

- Neue mathematische PID-Analysen und informationstheoretische Repräsentationsanalyse; formale Verifikation ausgewählter Ergebnisse und Protokolleigenschaften mit Lean und SMT
- Engrams domänenspezifischer KI-Agent erzeugt Modellkandidaten für Closed-Loop-Netzwerksimulationen in reproduzierbaren Computational-Neuroscience-Workflows; mit Provenienz sowie begrenzten Kompilierungs- und Simulationsprüfungen

Master of Research in Biowissenschaften: Neurowissenschaften
2012 - 2014

University College London London, Vereinigtes Königreich

Computational Neuroscience • Abschluss mit Auszeichnung (Distinction, Top 10 %, CGPA 4.0/4.0)

Bachelor of Science (Honours) in Informatik
2009 - 2012

Anglia Ruskin University Cambridge, Vereinigtes Königreich

Abschluss mit First Class Honours (Top 1 %, CGPA 4.0/4.0)

AUSGEWÄHLTE AUSZEICHNUNGEN & FÖRDERUNGEN

EDTH / 2025
Special Mention beim European Defense Tech Hackathon Berlin 2025; mitveranstaltet vom Cyber Innovation Hub der Bundeswehr

HUMAN BRAIN PROJECT
Forschungsförderung

NEAR HORIZON
Förderung für Confidential Computing

UCL & SHEFFIELD
Im Wettbewerb vergebene Hochschulstipendien

IOS-ANWENDUNGEN
15 internationale Produktauszeichnungen



UNTERSCHRIFT
Sepehr Mahmoudian

ORT Berlin, Deutschland
DATUM 13. November 2026

ÖFFENTLICHES ENGINEERING-PORTFOLIO

GITHUB Open-Source-Projekte
github.com/sepahead

HUGGING FACE Modelle & Datensätze
huggingface.co/torusprime

AUSGEWÄHLTE PROJEKTE

engram

★ 15 · FORSCHUNGSPROTOTYP

PROVENIENZGEBUNDENE NEURONALE FORSCHUNG

Domänenspezifischer KI-Agent überführt qualifizierte Evidenz in neuronale Modellkandidaten; Kompilierung und Simulation werden begrenzt geprüft.

Neuronale Netze · Wissensgraphen · Closed-Loop-Simulation

pid-rs

★ 15 · V0.9-QUELLVORABVERSION

PRÜFBARE INFORMATIONSZERLEGUNG

Zerlegt Information in Redundanz, quellenspezifische Anteile und Synergie; ausgewählte Lean-/SMT-Beweise und deklarierte Schätzannahmen.

Rust / Python · Informationstheorie · Lean / SMT

prisoma

★ 5 · V0.9-VORABVERSION / AKTIVE F&E

PRÜFBARE CLOSED-LOOP-EXPERIMENTE

Simulationsumgebung für Closed-Loop-Experimente mit VLA- und World-Model-Systemen; Aufzeichnung, Replay und Provenienz.

Rust / Python · VLA + World Models · Verkörperte Simulation

NCP

★ 16 · SDK 1.0.1 / NCP 2.0 VORBEREITET

PROTOKOLL FÜR NEURONALE STEUERUNG

Koppelt getrennt laufende Simulatoren, Roboter und Werkzeuge: kein Schritt doppelt, eindeutige Ergebnisse nach Fehlern, prüfbare Hashketten.

Rust / Python · Lean-Beweise · Fehlerinjektion

manwe

★ 6 · ALPHA

LUFTRAUMWAHRNEHMUNG

Forschungswerkzeug für Bilddaten, Akustik, Mehrkamerageometrie und Tracking; Modellexporte durchlaufen Artefaktidentitäts- und Numerikprüfungen.

Python · PyTorch · Multimodale Wahrnehmung

crebain

★ 23 · FORSCHUNGSPROTOTYP

RÄUMLICHES LAGEBILD

Bündelt Gaussian-Splat-Szenen, native Objekterkennung und multimodales 3D-Tracking in einer taktischen Ansicht für simulierte Drohneneinsätze.

Rust · Sensorfusion · Native Inferenz

melkor

★ 13 · HÄRTUNG

INTEGRITÄT VON GAUSSIAN SPLATS

Prüft und konvertiert 3D-Gaussian-Splats deterministisch; legt numerische Risiken und Feldherkunft vor dem Pipeline-Einsatz offen.

C++ · Szenenrekonstruktion · Asset-Validierung

cobot-atlas
relief-atlas

★ 8 · ↓ 3.271 · VERÖFFENTLICHT + DOI

KI-GENERIERTE SIMULATIONSDATENSÄTZE

Cobot Atlas veröffentlicht Robotik-Meshes mit DOI; Relief Atlas entwickelt Katastrophenschutz-Assets und Erzeugungspipelines.

Python · Hugging Face · 3D / VLA

galadriel

★ 8 · FORSCHUNGSPROTOTYP

SENSORÜBERGREIFENDE KONSISTENZ

Fail-Closed-Monitor für Sensorwidersprüche auf einer Objektspur: Innovationstests und vorzeichenbehaftete Korrelation auf deklarierten Projektionen.

Rust · NIS / CUSUM · Vorzeichenbehaftete Korrelation

cortexel

★ 5 · 0.10.0-DEV.0

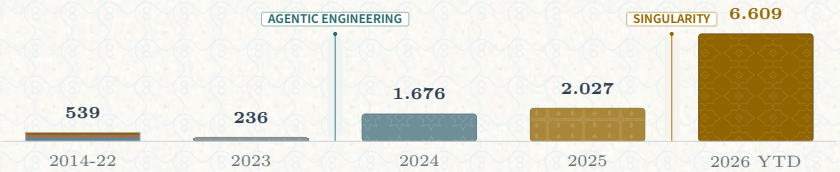
PRÜFBARE NEURONALE ABBILDUNGEN

Prüft wissenschaftliche Abbildungen gegen deklarierte Verträge; Diagramme passen nachweislich zu den Daten und bleiben reproduzierbar.

Abbildungsverträge · Deterministisches SVG · Provenienz

PORTFOLIO & ENTWICKLUNGSAKTIVITÄT

11.087	23	125	203
GITHUB-BEITRÄGE SEIT 2014	ÖFFENTLICHE REPOSITORIES OHNE FORKS	STARS AUF ÖFFENTLICHEN REPOSITORIES	AKTIVE TAGE IN 2026



AKTUELLE DYNAMIK

3,26× Beiträge 2026 bisher gegenüber dem Gesamtjahr 2025

6.609 bisher • 2.027 im Jahr 2025

BEITRÄGE NACH WOCHENTAG



6.609 Beiträge • 2026 bisher

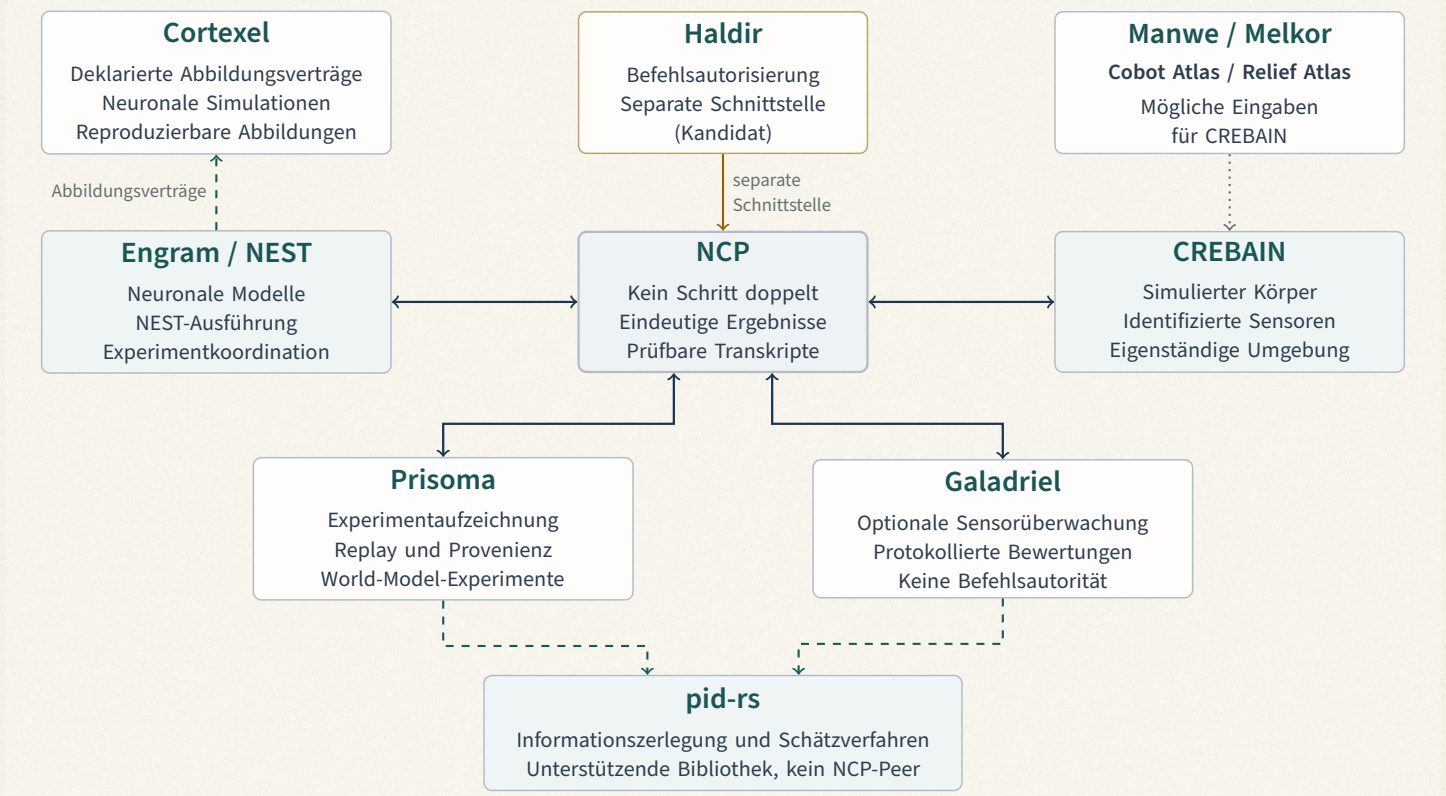
Mo 17,2%	Di 13,5%
Mi 12,3%	Do 9,8%
Fr 11,0%	Sa 18,9%
So 17,4%	

TECHNISCHE KENNTNISSE

• AGENTISCHE KI	LLMs / VLMs | Agent Harnesses | AI Agents | Tool Use | Model Evaluation | Inference Pipelines
• MACHINE LEARNING	Python | PyTorch | Agentic Vision | Multimodal AI | Vision-Language-Action / VLA Evaluation
• WISSEN & RETRIEVAL	Knowledge Graphs | Graph RAG | RAG | Embeddings | Vector Search | Reranking | Data Provenance
• SYSTEME & MLOPS	Rust | C++ | FastAPI | ONNX | TensorRT | CUDA | Metal / Core ML | Docker
• CLOUD & INFRASTRUKTUR	GCP | AWS | Azure | Kubernetes | Terraform | GitHub Actions | Linux | Zenoh
• FORMALE VERIFIKATION	Formale Methoden | Lean | SMT / Z3 | Model Checking | Differenztests

FORSCHUNGSÖKOSYSTEM

Eigenständig nutzbare Projekte für Experimente mit neuronalen und verkörperten Systemen. Jedes Programm verwaltet seinen eigenen Zustand; NCP definiert gemeinsame Verträge ohne zentrale Laufzeitinstanz. Die Karte trennt im Quellcode vorhandene Schnittstellen von möglichen Eingaben.



Lokale Anfragen und Ergebnisse im Quellcode
Nutzt eine unterstützende Bibliothek
Mögliche Eingabe; Adapter nicht belegt

Neuronaler Regelkreis

Engram verwaltet die neuronale Ausführung in NEST. CREBAIN verwaltet den simulierten Körper und die Sensorzustände. Über NCP 2 steuerten spikende Controller in NEST eine oder mehrere simulierte Drohnen, jede Aktion rückverfolgbar zu ihrer Beobachtung; die finale Aktuation bleibt beim Körper.

Evidenz und Analyse

Prisoma zeichnet Experimentaustausche auf. Galadriel protokolliert optionale Diagnostik. Ihre Analysepfade im Quellcode nutzen pid-rs; Engrams Abbildungspfad nutzt Cortexel. Aufzeichnung und Überwachung erteilen keine Steuerungsbefugnis.

Qualifikation

Aktuelle Beispiele starten mit expliziten Plänen und Szenen. Die Integrationsqualifikation bleibt teilweise offen. Manwe, Melkor und die Atlanten sind mögliche Modell- oder Assetquellen. Die Reproduktion beliebiger Fachartikel bleibt Forschungsziel.

Warum NCP

Begründung

Getrennt betriebene Programme fallen unabhängig aus: Eine Antwort kann verloren gehen, ein Schritt doppelt laufen und ein veralteter Befehl einen neueren Zustand treffen.

Eigenschaften

Ein Roundtrip pro Schritt; eine wiederholte Anfrage läuft nie doppelt; jeder Fehler hat ein eindeutiges Ergebnis; SHA-256-Digests verketten jede Sitzung zu einem prüfbaren Transkript; Owner-Regeln in Lean bewiesen.

Abgrenzung

MUSIC braucht einen gemeinsamen MPI-Job und lieferte im getesteten NEST-Build nur mit einem Thread exakte Spikes. gRPC, ZeroMQ, Zenoh und HTTP bringen keine dieser Garantien mit.

Leistung

9 µs pro Aufruf in Rust und 39 µs in Python; 23 bis 32 µs zusätzlich je 1-ms-NEST-Schritt (NCP 1: 228 bis 248 µs); kein falsches Ergebnis in 8.730 Fehlerversuchen.