

Sepehr Mahmoudian

SENIOR-KI-ENTWICKLER

Machine Learning • Wissensgraphen • Multimodale KI & Embodied AI

E-MAIL sepmhn@gmail.com

GITHUB github.com/sepahead

LINKEDIN linkedin.com/in/sepehr-mahmoudian

Berlin-Brandenburg • verfügbar ab November 2026 • Staatsangehörigkeit: deutsch • Deutsch: gut / Englisch: fließend / Persisch: Muttersprache



PROFIL

Entwickelt maßgeschneiderte Agenten-Harnesses für Fachanwendungen, Wissensgraphen und Graph RAG; evaluiert LLM-, VLM- und VLA-Systeme sowie World Models.

LLMs / VLMs • Wissensgraphen • Agentic Vision • Multimodale KI • Szenenrekonstruktion
CONTEXT ENGINEERING • DATENPROVENIENZ • MODELLVALIDIERUNG • REINFORCEMENT LEARNING

KI-ENGINEERING

10+ JAHRE

FORSCHUNG BIS PRODUKTIVEINSATZ

PYTHON • RUST • KI / ML

BERUFSERFAHRUNG

Selbstständiger KI- und ML-Entwickler & Doktorand

2020.04 - heute

Selbstständig; Promotion an der Technischen Universität Darmstadt • Berlin & Darmstadt, Deutschland

- Biophysikalische/funktionale neuronale Modelle, PID (Partial Information Decomposition), VLA-Evaluation und neuronale Steuerung
- Aufbau domänenspezifischer KI-Agenten-Harnesses; multimodale 3D-Wahrnehmung und prüfbare Visualisierung

Senior AI Engineer

2026.01 - 2026.03

Neural Frames UG • Berlin & Hamburg, Deutschland

- Evaluation von LLMs, VLMs und End-to-End-Pipelines; Langfuse-Tracing von Läufen und Ergebnissen
- Begrenzte Mitarbeit an Python-Pipelines für Modellevaluation und Inferenz

AI Engineering Resident

2025.09 - 2026.01

Merantix AI Campus (Hacker Room) • Berlin, Deutschland

- Entwicklung generativer Mediensysteme mit Gaussian Splatting und Diffusionsmodellen zur räumlich-zeitlichen Verankerung
- Implementierung von Smart Contracts in Rust für Confidential Computing
- Bereitstellung von Produktservices und Dateninfrastruktur auf Cloudflare Workers, D1, R2, Google Cloud Run und AWS EC2

Senior AI Engineer

2024.07 - 2025.07

Vision Labs UG • Berlin & Hamburg, Deutschland

- Aufbau von Workflows für Prompt-Optimierung, LLM-Evaluation und Observability mit DSPy und Langfuse
- Konzeption von Daten- und MLOps-Pipelines auf Azure und Google Cloud mit Staging, automatisierten Tests und CI/CD

Wissenschaftlicher Mitarbeiter

2021.07 - 2024.07

Freie Universität Berlin • Berlin, Deutschland

- Skalierung und Optimierung groß angelegter Simulationen neuronaler Netze in C/C++ und Python
- Entwicklung von RAG-Workflows für Fachliteratur und Evaluation der Zuverlässigkeit von KI-Agenten
- Statistische und ML-Analysen in Python; Code- und Manuskriptreviews in einem internationalen Team

Wissenschaftlicher Mitarbeiter

2019.07 - 2020.06

Georg-August-Universität Göttingen • Göttingen, Deutschland

Neuronale Netze, Partial Information Decomposition (PID), Informationstheorie und reproduzierbare Daten-Workflows

Wissenschaftlicher Mitarbeiter

2017.03 - 2019.07

Goethe-Universität Frankfurt • Frankfurt am Main, Deutschland • Simulation und statistische Analyse neuronaler Netzmodelle

Gastwissenschaftler

2017.03 - 2019.03

Max-Planck-Institut für Dynamik und Selbstorganisation • Göttingen, Deutschland • Statistische Methoden zur Analyse neuronaler Netze

Wissenschaftlicher Mitarbeiter

2015.02 - 2017.03

Forschungszentrum Jülich • Jülich, Deutschland • Simulationen neuronaler Netze und Experimente zum Reinforcement Learning

Softwareentwickler

2010.09 - 2012.03

Centre for Content Creation • Cyberjaya, Malaysia • Preisgekrönte iPhone- und iPad-Anwendungen sowie digitale Produkte

AKADEMISCHE AUSBILDUNG

Promotion zum Dr. rer. nat.

2020.04 - heute

Technische Universität Darmstadt • Darmstadt, Deutschland

• Neue mathematische PID-Analysen und informationstheoretische Repräsentationsanalyse; Engrams domänenspezifischer KI-Agent erzeugt für reproduzierbare Computational-Neuroscience-Workflows provenienzengebundene neuronale Modellkandidaten für Closed-Loop-Netzwerksimulationen mit begrenzten Kompilierungs- und Simulationsprüfungen

Master's by Research in Biosciences: Neuroscience

2012 - 2014

University College London • London, Vereinigtes Königreich

Computational Neuroscience • Abschluss mit Auszeichnung (Distinction, Top 10 %, CGPA 4.0/4.0)

Bachelor of Science (Honours) in Computer Science

2009 - 2012

Anglia Ruskin University • Cambridge, Vereinigtes Königreich

Abschluss mit First Class Honours (Top 1 %, CGPA 4.0/4.0)

AUSGEWÄHLTE AUSZEICHNUNGEN & FÖRDERUNGEN

EDTH / 2025

Special Mention beim European Defense Tech Hackathon Berlin 2025; mitveranstaltet vom Cyber Innovation Hub der Bundeswehr

HUMAN BRAIN PROJECT

Forschungsförderung

NEAR HORIZON

Förderung für Confidential Computing

UCL & SHEFFIELD

Im Wettbewerb vergebene Hochschulstipendien

IOS-ANWENDUNGEN

15 internationale Produktauszeichnungen

UNTERSCHRIFT

Sepehr Mahmoudian

ORT Berlin, Deutschland

DATUM 13. August 2026

ÖFFENTLICHES ENGINEERING-PORTFOLIO

GITHUB Open-Source-Projekte

github.com/sepahead

HUGGING FACE Modelle & Datensätze

huggingface.co/torusprime



AUSGEWÄHLTE PROJEKTE IM KI-ENGINEERING

engram

FORSCHUNGSPROTOTYP

PROVENIENZGEBUNDENE NEURONALE FORSCHUNG

Domänenspezifischer KI-Agent überführt qualifizierte Evidenz in neuronale Modellkandidaten; Kompilierung und Simulation werden begrenzt geprüft.

Python Knowledge Graphs NEST

pid-rs

V0.9-QUELLVORABVERSION

PRÜFBARE INFORMATIONSZERLEGUNG

Misst, wie viel Information mehrere Signale über eine Zielgröße teilen; eingebaute Prüfungen und Provenienz sichern reproduzierbare Ergebnisse.

Rust / Python Information Theory Statistical ML

prisoma

V0.9-VORABVERSION / AKTIVE F&E

PRÜFBARE VLA-EXPERIMENTE

Zeichnet VLA-Läufe auf, erlaubt Intervention und Replay; jeder Lauf bleibt prüfbar und reproduzierbar.

Rust / Python VLA Evals Intervention / Replay

NCP

V0.8-RELEASE / 1.0-RC BLOCKIERT

PROTOKOLL FÜR NEURONALE STEUERUNG

Verbindet neuronale Simulatoren, KI-Controller und Roboter über vier typisierte Ebenen mit lokalen Fail-Safes und Provenienz.

Rust Canonical JSON Zenoh

manwe

ALPHA

LUFTRAUMWAHRNEHMUNG

Forschungswerkzeug für Bilddaten, Akustik, Mehrkamergeometrie und Tracking; Modellexporte durchlaufen Artefaktidentitäts- und Numerikprüfungen.

Python PyTorch Model Export

crebain

FORSCHUNGSPROTOTYP

RÄUMLICHES LAGEBILD

Bündelt Gaussian-Splat-Szenen, native Objekterkennung und multimodales 3D-Tracking in einer taktischen Ansicht für simulierte Drohneneinsätze.

Rust Sensor Fusion Native Inference

melkor

HÄRTUNG

INTEGRITÄT VON GAUSSIAN SPLATS

Prüft und konvertiert 3D-Gaussian-Splats deterministisch; legt numerische Risiken und Feldherkunft vor dem Pipeline-Einsatz offen.

C++ PLY / SPZ Asset Validation

cobot-atlas

VERÖFFENTLICHT + DOI

OFFENER ROBOTIKDATENSATZ

Zitierfähiger Robotik-Atlas mit 2.023 im Manifest gelisteten GLB-Pfaden und 1.936 unterschiedlichen Kennungen; die Erzeugungspipeline ist mitveröffentlicht.

Python Hugging Face 3D / VLA

galadriel

FORSCHUNGSPROTOTYP

SENSORÜBERGREIFENDE KONSISTENZ

Fail-Closed-Monitor für Sensorwidersprüche auf einer Objektspur: Innovationstests und vorzeichenbehaftete Korrelation auf deklarierten Projektionen.

Rust NIS / CUSUM Signed Correlation

cortexel


0.10.0-DEV.0

PRÜFBARE NEURONALE ABBILDUNGEN

Prüft wissenschaftliche Abbildungen gegen deklarierte Verträge; Diagramme passen nachweislich zu den Daten und bleiben reproduzierbar.

Figure Contracts Deterministic SVG Provenance

PORTFOLIO & ENTWICKLUNGSAKTIVITÄT



TECHNISCHE KENNTNISSE

KI-/ML-ENGINEERING

AGENTISCHE KI	LLMs / VLMs Agent Harnesses AI Agents Tool Use Model Evaluation Inference Pipelines
MACHINE LEARNING	Python PyTorch Agentic Vision Multimodal AI Vision-Language-Action / VLA Evaluation
WISSEN & RETRIEVAL	Knowledge Graphs Graph RAG RAG Embeddings Vector Search Reranking Data Provenance
SYSTEME & MLOPS	Rust C++ FastAPI ONNX TensorRT CUDA Metal / Core ML Docker
CLOUD & INFRASTRUKTUR	GCP AWS Azure Kubernetes Terraform GitHub Actions Linux Zenoh