

Sepehr Mahmoudian

SENIOR-KI-ENTWICKLER

Machine Learning • Wissensgraphen • Multimodale KI & Embodied AI

E-MAIL sepmhn@gmail.com

GITHUB github.com/sepahead

LINKEDIN linkedin.com/in/sepehr-mahmoudian

Berlin-Brandenburg • verfügbar ab November 2026 • Staatsangehörigkeit: deutsch • Deutsch: gut / Englisch: fließend / Persisch: Muttersprache



PROFIL

Entwickelt maßgeschneiderte Agenten-Harnesses für Fachanwendungen, Wissensgraphen und Graph RAG; evaluiert LLM-, VLM- und VLA-Systeme sowie World Models und verbindet agentische Orchestrierung mit konsequentem agentischen Engineering.

LLMs / VLMs • Wissensgraphen • Agentic Vision • Multimodale KI • Szenenrekonstruktion
CONTEXT ENGINEERING • DATENPROVENIENZ • MODELLEVALUATION • REINFORCEMENT LEARNING

KI-ENGINEERING

10+ JAHRE

FORSCHUNG BIS PRODUKTIVEINSATZ

PYTHON • RUST • KI / ML

BERUFSERFAHRUNG

Selbstständiger KI- und ML-Entwickler & Doktorand

2020.04 - heute

Selbstständig; Promotion an der Technischen Universität Darmstadt

Berlin & Darmstadt, Deutschland

- Biophysikalische/funktionale neuronale Modelle, PID (Partial Information Decomposition), VLA-Evaluation und neuronale Steuerung
- Aufbau domänenspezifischer KI-Agenten-Harnesses; multimodale 3D-Wahrnehmung und prüfbare Visualisierung

Senior-KI-Entwickler

2026.01 - 2026.03

Neural Frames UG

Berlin & Hamburg, Deutschland

- Evaluation von LLMs, VLMs und End-to-End-Pipelines; Langfuse-Tracing von Läufen und Ergebnissen
- Begrenzte Mitarbeit an Python-Pipelines für Modellevaluation und Inferenz

KI-Engineering-Resident

2025.09 - 2026.01

Merantix AI Campus (Hacker Room)

Berlin, Deutschland

- Entwicklung generativer Mediensysteme mit Gaussian Splatting und Diffusionsmodellen zur räumlich-zeitlichen Verankerung
- Implementierung von Smart Contracts in Rust für Confidential Computing
- Bereitstellung von Produktservices und Dateninfrastruktur auf Cloudflare Workers, D1, R2, Google Cloud Run und AWS EC2

Senior-KI-Entwickler

2024.07 - 2025.07

Vision Labs UG

Berlin & Hamburg, Deutschland

- Aufbau von Workflows für Prompt-Optimierung, LLM-Evaluation und Observability mit DSPy und Langfuse
- Konzeption von Daten- und MLOps-Pipelines auf Azure und Google Cloud mit Staging, automatisierten Tests und CI/CD

Wissenschaftlicher Mitarbeiter

2021.07 - 2024.07

Freie Universität Berlin

Berlin, Deutschland

- Skalierung und Optimierung groß angelegter Simulationen neuronaler Netze in C/C++ und Python
- Entwicklung von RAG-Workflows für Fachliteratur und Evaluation der Zuverlässigkeit von KI-Agenten
- Statistische und ML-Analysen in Python; Code- und Manuskriptreviews in einem internationalen Team

Wissenschaftlicher Mitarbeiter

Georg-August-Universität Göttingen

Göttingen, Deutschland

Neuronale Netze, Partial Information Decomposition (PID), Informationstheorie und reproduzierbare Daten-Workflows

2019.07 - 2020.06

Wissenschaftlicher Mitarbeiter

Goethe-Universität Frankfurt

Frankfurt am Main, Deutschland

Simulation und statistische Analyse neuronaler Netzmodelle

2017.03 - 2019.07

Gastwissenschaftler

Max-Planck-Institut für Dynamik und Selbstorganisation

Göttingen, Deutschland

Statistische Methoden zur Analyse neuronaler Netze

2017.03 - 2019.03

Wissenschaftlicher Mitarbeiter

Forschungszentrum Jülich

Jülich, Deutschland

Simulationen neuronaler Netze und Experimente zum Reinforcement Learning

2015.02 - 2017.03

Softwareentwickler

Centre for Content Creation

Cyberjaya, Malaysia

Preisgekrönte iPhone- und iPad-Anwendungen sowie digitale Produkte

2010.09 - 2012.03

AKADEMISCHE AUSBILDUNG

Promotion zum Dr. rer. nat.

Technische Universität Darmstadt

Darmstadt, Deutschland

• Neue mathematische PID-Analysen und informationstheoretische Repräsentationsanalyse; Engrams domänenspezifischer KI-Agent erzeugt für reproduzierbare Computational-Neuroscience-Workflows provenienzengebundene neuronale Modellkandidaten für Closed-Loop-Netzwerksimulationen mit begrenzten Kompilierungs- und Simulationsprüfungen

2020.04 - heute

Master of Research in Biowissenschaften: Neurowissenschaften

University College London

London, Vereinigtes Königreich

Computational Neuroscience • Abschluss mit Auszeichnung (Distinction, Top 10 %, CGPA 4.0/4.0)

2012 - 2014

Bachelor of Science (Honours) in Informatik

Anglia Ruskin University

Cambridge, Vereinigtes Königreich

Abschluss mit First Class Honours (Top 1 %, CGPA 4.0/4.0)

2009 - 2012

AUSGEWÄHLTE AUSZEICHNUNGEN & FÖRDERUNGEN

EDTH / 2025

Special Mention beim European Defense Tech Hackathon Berlin 2025; mitveranstaltet vom Cyber Innovation Hub der Bundeswehr

HUMAN BRAIN PROJECT

Forschungsförderung

NEAR HORIZON

Förderung für Confidential Computing

UCL & SHEFFIELD

Im Wettbewerb vergebene Hochschulstipendien

IOS-ANWENDUNGEN

15 internationale Produktauszeichnungen

UNTERSCHRIFT

Sepehr Mahmoudian

ORT Berlin, Deutschland

DATUM 26. August 2026

ÖFFENTLICHES ENGINEERING-PORTFOLIO

GITHUB Open-Source-Projekte
github.com/sepahead

HUGGING FACE Modelle & Datensätze
huggingface.co/torusprime



AUSGEWÄHLTE PROJEKTE



engram

★ 15FORSCHUNGSPROTOTYP

PROVENIENZGEBUNDENE NEURONALE FORSCHUNG

Domänenspezifischer KI-Agent überführt qualifizierte Evidenz in neuronale Modellkandidaten; Kompilierung und Simulation werden begrenzt geprüft.

Neuronale NetzeWissensgraphenClosed-Loop-Simulation



prisoma

★ 2V0.9-VORABVERSION / AKTIVE F&E

PRÜFBARE CLOSED-LOOP-EXPERIMENTE

Simulationsumgebung für Closed-Loop-Experimente mit VLA- und World-Model-Systemen; Aufzeichnung, Replay und Provenienz.

Rust / PythonVLA + World ModelsVerkörpernte Simulation



manwe

★ 3ALPHA

LUFTRAUMWAHRNEHMUNG

Forschungswerkzeug für Bilddaten, Akustik, Mehrkamergeometrie und Tracking; Modellexporte durchlaufen Artefaktidentitäts- und Numerikprüfungen.

PythonPyTorchMultimodale Wahrnehmung



melkor

★ 13HÄRTUNG

INTEGRITÄT VON GAUSSIAN SPLATS

Prüft und konvertiert 3D-Gaussian-Splats deterministisch; legt numerische Risiken und Feldherkunft vor dem Pipeline-Einsatz offen.

C++SzenenrekonstruktionAsset-Validierung



galadriel

★ 7FORSCHUNGSPROTOTYP

SENSORÜBERGREIFENDE KONSISTENZ

Fail-Closed-Monitor für Sensorwidersprüche auf einer Objektspur: Innovationstests und vorzeichenbehaftete Korrelation auf deklarierten Projektionen.

RustNIS / CUSUMVorzeichenbehaftete Korrelation



pid-rs

★ 14V0.9-QUELLVORABVERSION

PRÜFBARE INFORMATIONSZERLEGUNG

Misst, wie viel Information mehrere Signale über eine Zielgröße teilen; eingebaute Prüfungen und Provenienz sichern reproduzierbare Ergebnisse.

Rust / PythonInformationstheorieStatistisches ML



NCP

★ 16V0.8-RELEASE / 1.0-RC BLOCKIERT

PROTOKOLL FÜR NEURONALE STEUERUNG

Verbindet neuronale Simulatoren, KI-Controller und Roboter über vier typisierte Ebenen mit lokalen Fail-Safes und Provenienz.

RustTypisierte SteuerungsebenenZenoh



crebain

★ 21FORSCHUNGSPROTOTYP

RÄUMLICHES LAGEBILD

Bündelt Gaussian-Splat-Szenen, native Objekterkennung und multimodales 3D-Tracking in einer taktischen Ansicht für simulierte Drohneneinsätze.

RustSensorfusionNative Inferenz



cobot-atlas

★ 7↓ 1.850VERÖFFENTLICHT + DOI

relief-atlas

KI-GENERIERTE SIMULATIONSDATENSÄTZE
2.023 Robotik- und 10.079 Katastrophenschutz-GLB-Meshes mit Erzeugungspipelines.

PythonHugging Face3D / VLA



cortexel


★ 40.10.0-DEV.0

PRÜFBARE NEURONALE ABBILDUNGEN

Prüft wissenschaftliche Abbildungen gegen deklarierte Verträge; Diagramme passen nachweislich zu den Daten und bleiben reproduzierbar.

AbbildungsverträgeDeterministisches SVGProvenienz

PORTFOLIO & ENTWICKLUNGSAKTIVITÄT



TECHNISCHE KENNTNISSE

KI-/ML-ENGINEERING

• AGENTISCHE KI	LLMs / VLMs Agent Harnesses AI Agents Tool Use Model Evaluation Inference Pipelines
• MACHINE LEARNING	Python PyTorch Agentic Vision Multimodal AI Vision-Language-Action / VLA Evaluation
• WISSEN & RETRIEVAL	Knowledge Graphs Graph RAG RAG Embeddings Vector Search Reranking Data Provenance
• SYSTEME & MLOPS	Rust C++ FastAPI ONNX TensorRT CUDA Metal / Core ML Docker
• CLOUD & INFRASTRUKTUR	GCP AWS Azure Kubernetes Terraform GitHub Actions Linux Zenoh